

Menaces, attaques et défenses dans l'apprentissage fédéré :

Enseignant : Rachid Elazouzi

Étudiants :

- Thibault Coupigny
- Ethan Bernon
- Noé Seiler
- Orlane Bétouille

I - Comprendre le fonctionnement de l'apprentissage centralisé, en particulier les réseaux neuronaux convolutifs et récurrents :

L'apprentissage centralisé :

L'apprentissage centralisé est la méthode traditionnelle pour entraîner des modèles d'apprentissage automatique. Dans ce type d'apprentissage les données sont toutes stockées sur un serveur central, le modèle est entraîné sur ces données, avant d'être déployé pour les utilisateurs.

Les réseaux de neurones :

Un réseau de neurones est composé de plusieurs couches de neurones, dans lesquelles chaque neurone contient une valeur


entre 0 et 1 représentant son niveau d'activation. Chaque neurone d'une couche est relié à tous les neurones de la couche suivante, le niveau d'activation se propage ainsi vers les couches suivantes en étant modifié par un poids attribué à chaque liaison. Ce poids permet de définir l'importance de la liaison dans l'activation du neurone suivant.

Le neurone de la dernière couche avec le niveau d'activation le plus haut donne le résultat de la prédiction. Pour traquer la précision d'un réseau neuronal une fonction de perte est mise en place (cost function), cette fonction calcule la différence entre le résultat attendu et celui obtenu. Donc plus le résultat de celle-ci est haut moins le modèle est performant, l'objectif général est donc de minimiser la valeur de cette fonction en modifiant les poids.

Pour ce faire nous faisons appel à un outil mathématique, le gradient, celui-ci donne la direction de la variation la plus forte d'une fonction. En allant dans la direction opposée au gradient ce qui correspond à un déplacement minimisant le résultat de la fonction permettant ainsi une plus grande précision du réseau neuronal. Les changements à administrés aux poids sont faits de la dernière à la première couche, c'est la rétropropagation du gradient.


Les réseaux Convolutifs :

Les réseaux neuronaux convolutifs sont conçus spécialement pour traiter des données avec une structure en grille. Ils sont donc principalement utilisés pour faire du traitement d'images, tel que de la détection de visages ou d'objets. Dans le cadre d'une image, chaque neurone se voit assigner un pixel de l'image avec ses trois composantes : son niveau de rouge, son niveau de vert, et son niveau de bleu. L'image est donc vu comme un volume, sa hauteur et largeur correspondent à ses dimensions, sa profondeur sera ses trois composantes RGB. (Cf : Schéma explicatif)



Les réseaux récurrents :

Les réseaux neuronaux récurrents sont conçus plus spécialement pour traiter des données de taille variable en entrée et excellents dans les domaines du traitement de séries temporelles, de la parole, du texte ou encore de la traduction automatique. Le réseau neuronal récurrent possède, contrairement à l'autre type de réseau neuronal abordé, une mémoire interne qui lui permet de stocker une information des éléments précédents. Ce qui lui permet d'écrire "le chat mange une souris" bien plus fréquemment que "le chat mange une voiture" lors d'une génération de texte par exemple. Cependant de part sa nature récurrente le réseau neuronal fait face à une disparition du gradient ce qui l'empêche de modifier ses poids en fonction d'événements trop anciens.



Sources :

- [Wikipédia : Convolutional neural network](#)
- [Wikipédia : Recurrent neural network](#)
- [Wikipédia : Gradient](#)
- [Wikipédia : Gradient descent](#)

II - Comprendre la différence entre l'apprentissage centralisé et l'apprentissage fédéré.

L'apprentissage Centralisé :

L'apprentissage centralisé est l'approche conventionnelle de la science des données. Dans ce modèle, l'ensemble des données brutes collectées auprès des utilisateurs est transféré vers un serveur unique ou un centre de données (Data Center). Les données sont envoyées depuis les périphériques vers un stockage central. Le modèle d'IA est entraîné à l'aide de puissantes ressources de calcul (CPU/TPU).

Cette méthode pose des problèmes majeurs de confidentialité, car une faille de sécurité sur le serveur central expose l'intégralité des données. De plus, le coût de transfert de données assez volumineuses peut être prohibitif et onéreux.

L'apprentissage Fédéré :

Contrairement au modèle classique où toutes les données se trouvent sur un seul serveur, l'apprentissage fédéré permet d'entraîner des algorithmes sans échanger de données brutes. Les données restent là où elles ont été générées.

Les appareils locaux apprennent de manière autonome et ne partagent que des résumés statistiques avec le serveur central.

Comparaison et Différences :

La différence fondamentale réside dans la gestion de données :

Le centralisé déplace la donnée vers l'algorithme.

Le fédéré déplace l'algorithme vers la donnée.

<u>Caractéristiques</u>	<u>Apprentissage centralisé</u>	<u>Apprentissage fédéré</u>
<i>Localisation des données</i>	<i>Tout est regroupé sur un serveur central unique</i>	<i>Les données restent sur les appareils locaux et ne sont pas partagées</i>
<i>Confidentialité</i>	<i>Risque élevé : Toutes les données fuiteront en même temps</i>	<i>Risque réduit : Seuls les données de l'appareil fuiteront</i>
<i>Flux et Transfert</i>	<i>Nécessite une bande passante importante pour envoyer les fichiers lourds</i>	<i>Envoi de petits fichiers de mise à jour</i>

Lequel privilégier ?

L'apprentissage centralisé est idéal lorsque la rapidité du développement est la priorité et que les données ne sont pas sensibles.

L'apprentissage fédéré est la solution pour le respect de la vie privée. C'est le meilleur choix lorsque l'on traite des informations personnelles ou confidentielles.

Sources :


- [Apprentissage fédéré : définition, fonctionnement et application.](#)
- [Google cloud : L'apprentissage fédéré, présentation et fonctionnement](#)

III - Explorer différents types d'apprentissage fédéré.

Apprentissage vertical :

Principe :

Lors d'un apprentissage vertical (Vertical Federated Learning en anglais), on peut représenter les données de façon visuelle via un tableau où chaque ligne correspondrait à un individu que l'on nomme un "Sample" et où chaque colonne représente les caractéristiques utilisés pour classer ces individus que l'on nomme des "Features". Ici, chacun des agents possède un ou plusieurs des Features de l'ensemble des Samples sans connaître ceux des autres agents ce qui fait qu'ils ne connaissent que partiellement le jeu de données.



Le protocole d'entraînement :

Le protocole d'entraînement est donc le suivant : chaque client transforme ses données locales en embeddings via son modèle, ces embeddings sont concaténés et transmis au modèle global pour le calcul de gradient, puis ces derniers sont renvoyés à chaque client pour la mise à jour des modèles locaux.

Mise en forme des données :

Deux types de modèles sont utilisés en VFL : les modèles à base d'arbres et ceux à base de réseaux de neurones.

Les réseaux de neurones sont utiles dans les cas où la donnée à traiter est difficilement représentable sous forme de tableau avec des lignes et des colonnes, avec chaque cellule étant un nombre ou une catégorie. On les utilise plutôt lorsque l'on veut traiter des données complexes : des images, du texte, de l'audio, des vidéos. Le réseau de neurone est dit plus "expressif" parce qu'il peut apprendre des représentations abstraites et hiérarchiques : d'abord détecter des contours, puis des formes, puis des structures anatomiques, et finalement une anomalie par exemple, dans le cas de photographie médicales.

Quant à eux, les arbres utilisés sont des arbres de décisions (Decision tree learning) où les différentes décisions possibles sont situées aux extrémités des branches (les "feuilles" de l'arbre), et sont atteintes en fonction de décisions prises à chaque étape. Durant un VFL, chaque client entraîne un sous arbre qui sera ensuite regroupé pour former l'arbre global. Cette structure de données peut être utilisée car elle est adaptée pour les prédictions rapides avec une précision correcte. De plus, elle fonctionne très bien sur des données structurées en tableau. Qui plus est, elle ne nécessite pas beaucoup de puissance de calcul, ce qui est un avantage dans un contexte fédéré où les clients peuvent avoir des ressources limitées.

Sécurité des données :

Pour mettre en place ce système d'apprentissage, il faut s'assurer que tous les samples soient présents dans chacun des sous modèles. Cette étape est critique car elle nécessite d'identifier chaque sample sans envoyer de données critiques

aux autres clients. On peut aussi retrouver des fuites de données lors de la transmission des embeddings ou des gradients. Mais surtout ce système laisse place à certaines attaques permettant de reconstruire les données ou bien les perturber :

Les attaques par inférence de features visent à reconstruire les features brutes d'autres clients à partir des gradients ou des sorties de prédiction.

Les attaques par empoisonnement injectent des perturbations dans les données pour dégrader la performance collaborative du modèle global.

Exemple d'utilisations :

Une grande entreprise comme META, qui possèdent plusieurs applications dans des domaines différents pourrait utiliser les VFL car les utilisateurs de ces applications sont souvent les mêmes (les samples seraient bien égaux pour chaque clients) et les domaines d'utilisation des applications sont différents (les clients possèdent des labels différents). Dans l'exemple de META, Facebook pourrait avoir des informations sur l'âge, la localisation ou les événements créée des utilisateurs, Instagram possèderait les types de photos liké, les hashtag suivis et enfin WhatsApp possèderait le nombre de contact, la fréquence de message ou d'appel. Chaque application entraînerait un modèle pour cibler avec plus de précision les contenus publicitaires intéressants pour l'utilisateur.

Sources :

- [Vertical Federated Learning for Effectiveness, Security, Applicability: A Survey](#)
- [Wikipédia : Apprentissage fédéré](#)
- [Data Franca wiki](#)

Apprentissage Horizontal:

L'apprentissage horizontal est le type d'apprentissage fédéré le plus répandu. Il s'applique dans les situations où plusieurs participants (hôpitaux, smartphones, entreprises) disposent du même type de données (les mêmes colonnes, les mêmes features) mais sur des individus différents. Chaque client possède donc son propre "échantillon" de données sans qu'elles soient partagées avec les autres.


Exemple d'utilisation concrète:

Trois hôpitaux différents collectent chacun des données de patients (age, tension, résultat d'analyse) Les colonnes sont donc identiques d'un hôpital à l'autre, mais les patients sont différents. Aucun des ces hôpitaux ne partage ses données pour des raisons de confidentialité et de réglementation. Le HFL (Horizontal Federated Learning) est donc plus adapté dans un cadre de confidentialité et de respect de traitement des données.

Entraînement HFL:


Dans ce cas, chacun des clients possède un sous-ensemble de points labellisés (bleu/orange). Comme dit ci-dessus aucun des clients ne connaît l'ensemble des points. Dans ce cas les 9 clients entraînent collectivement un modèle capable de tracer la bonne frontière de décision sans qu'il n'ait jamais partagé ses points bruts avec les autres.

Paramètres du réseau neuronal.





Liste des différents clients et leurs échantillons de données.


Local Models




Réseaux de neurones simples comportant deux couches cachées de respectivement 4 et 2 neurones.



Output a l'époque (génération) 0.
Les points en gras représentent les données de test.



A partir de l'époch 50 environ le model est capable avec une précision de 100% de déterminer où se trouvent les points bleu et orange.



La courbe représente les erreurs commises par les clients. On constate une nette diminution dès le début des tests stagnant à un taux d'erreur de 0.008 pour le pire client (le troisième) et de 0.002 pour le meilleur (le deuxième).



La courbe de convergence rate montre que le modèle apprend progressivement et de manière stable. Elle montre un pic au début car le modèle est initialisé aléatoirement. Cette hausse représente donc le temps que les premières epoch synchronisent les clients entre eux puis cette dernière descend régulièrement pour se rapprocher de 0.

Sources:

- [Réseaux neuronal](#)
- [Informations apprentissage fédéré](#)
- [Wikipédia : Apprentissage Fédéré](#)