

Menaces, attaques et défenses dans l'apprentissage fédéré

Public visé : Licence CMI Informatique

Enseignant : Rachid Elazouzi

Contexte

Les attaques empiriques contre les systèmes d'apprentissage fédéré (FL) indiquent que le FL présente de nombreuses surfaces d'attaque tout au long de son exécution. Ces attaques peuvent non seulement entraîner l'échec des modèles dans des tâches spécifiques, mais aussi permettre de déduire des informations privées. Par exemple, une attaque par empoisonnement vise à dégrader facilement les modèles d'apprentissage automatique. Elle peut être classée en deux catégories : les attaques par empoisonnement des données et les attaques par empoisonnement des modèles.

Compétences visées

- Comprendre le fonctionnement de l'apprentissage fédéré
- Être capable de mettre en place un apprentissage fédéré avec Flower
- Mettre en place des attaques sur un modèle d'apprentissage fédéré.
- Travailler en équipe.

Objectifs généraux

1. Réaliser une analyse approfondie des attaques potentielles qui pourraient menacer l'apprentissage fédéré.
2. Comprendre pourquoi l'apprentissage est plus vulnérable aux attaques.
3. Mettre en place des expériences démontrant l'efficacité de ces attaques.
4. Concevoir et mettre en œuvre une contre-mesure de base pour contrer ces attaques.

Déroulement du projet

1. Partie A

- a. Comprendre le fonctionnement de l'apprentissage centralisé, en particulier les réseaux neuronaux convolutifs et récurrents.
- b. Comprendre la différence entre l'apprentissage centralisé et l'apprentissage fédéré.
- c. Explorer différents types d'apprentissage fédéré.

2. Partie B

- a. Explorer différentes attaques susceptibles d'affecter le fonctionnement normal de l'apprentissage fédéré
- b. Mener des expériences démontrant l'efficacité de ces attaques avec les ensembles de données MNIST et CIFAR10.
- c. Tester l'impact de ces attaques en fonction du nombre de clients affectés.
- d. Implémentation des contre-mesures sur ces attaques.

3. Partie C

- a. Fournir des solutions pour chaque type d'attaque.
- b. Tester ces attaques dans différents types de scénarios : IID et non-IID, participation totale et participation partielle.

4. Partie D

- a. Rapport et diaporama de présentation du projet.
- b. Démo sur les attaques et les contre-mesures.

Critères d'évaluation

- Fonction de base de l'apprentissage fédéré
- La mise en place des attaques contre l'apprentissage fédéré
- Clarté et rigueur du code
- Qualité de la présentation finale
- Pertinence de la contre-mesure implémentée